

Predicción Multimodal de Quiebras Corporativas:
Aprendizaje Automático Optimizado por Coste de Negocio,
Calibración Prudencial y Explicabilidad Regulatoria



U N I V E R S I D A D
COMPLUTENSE
M A D R I D

Máster Data Science, Big Data & Business Analytics 2025-2026

Martín Herrera Roncero

1.	VISIÓN ESTRATÉGICA, MARCO REGULATORIO Y ASIMETRÍA DEL RIESGO CREDITICIO	4
1.1.	Contexto de negocio: Fragilidad en grandes empresas y destrucción de valor sistémico	4
1.2.	Marco regulatorio prudencial: Basilea III/IV y NIIF 9 / IFRS 9	4
1.3.	Desbalanceo extremo de clases y la falacia del accuracy	4
1.4.	Modelización de la pérdida asimétrica.....	5
1.5.	Objetivos estratégicos del proyecto	5
2.	ARQUITECTURA DE INGESTA EFICIENTE, CALIDAD DEL DATO Y GOBERNANZA	6
2.1.	Fuentes de datos y universo de empresas.....	6
2.2.	Arquitectura de ingesta columnar con DuckDB	6
2.3.	Formalización de la variable objetivo de insolvencia y su prevalencia	6
2.4.	Gobernanza del dato: Cero Look-Ahead Bias, imputación Sectorial y atípicos	7
3.	INTELIGENCIA MULTIMODAL: DE LA CONTABILIDAD TRADICIONAL A LA INTELIGENCIA ARTIFICIAL.....	8
3.1.	Ratios contables clásicos y modelo estructural de Merton KMV	8
3.2.	Detección no supervisada de regímenes económicos y arquetipos corporativos con GMM	8
3.3.	Minería de textos financieros y análisis de sentimiento con FinBERT y BERTopic.....	8
3.4.	Selección de variables	9
4.	METODOLOGÍA DE VALIDACIÓN Y MODELADO PREDICTIVO EN GPU.....	10
4.1.	Esquema de validación temporal: 5-fold purged group time series cross-validation	10
4.2.	Portafolio de modelos evaluados: del estándar regulatorio a los modelos avanzados	11
4.3.	Aceleración computacional en GPU y optimización bayesiana de hiperparámetros	12
4.4.	Calibración de probabilidades bajo la normativa contable IFRS 9.....	12
5.	RESULTADOS DEL BENCHMARK, FIABILIDAD PROBABILÍSTICA Y RIGOR ESTADÍSTICO	13
5.1.	Resultados del benchmark	13
5.2.	Contrastes estadísticos formales de superioridad: DeLong y McNemar	14
5.3.	Intervalos de confianza empíricos mediante remuestreo bootstrap al 95%.....	15
5.4.	Optimización del umbral óptimo de corte bajo costes asimétricos	15
6.	GESTIÓN OPERATIVA DEL RIESGO, PRUEBAS DE ESTRÉS Y MONITORIZACIÓN DE DERIVA	16
6.1.	Concentración operativa del riesgo: curvas de lift y ganancia acumulada	16
6.2.	Pruebas de resistencia macroeconómica (stress testing) y simulación Monte Carlo	16
6.3.	Monitorización de estabilidad temporal y gobernanza de data drift (PSI y KS)	17
7.	EXPLICABILIDAD PARA NEGOCIO (XAI) Y CUMPLIMIENTO NORMATIVO	18
7.1.	El imperativo regulatorio de la explicabilidad: superación de la caja negra	18
7.2.	Interpretabilidad global mediante valores SHAP (TreeExplainer)	19
7.3.	Interpretabilidad local, interacciones no lineales y cartas de acción adversa (ECO y FCRA).....	20
8.	INTEGRACIÓN OPERATIVA EN NEGOCIO	21
8.1.	Integración en el flujo de decisión crediticia y arquitectura operativa.....	21
9.	CONCLUSIONES Y VÍAS DE MEJORA.....	21
9.1.	Conclusiones.....	21
9.2.	Vías de mejora	22
	Bibliografía.....	22

Guía de Trazabilidad: Documento vs. Notebooks de Código

	Contenido	Notebook / Código
1. Visión Estratégica y Asimetría	Formulación de la función de coste asimétrico	03_Model_Training_GPU_and_Benchmark.ipynb
2. Arquitectura de Ingesta y Calidad	Ingesta SEC XBRL en DuckDB, nullos, retardos y gobernanza	01_EDA_FE.ipynb
3. Inteligencia Multimodal (Extracción)	Ratios contables, Merton KMV, clusters GMM y FinBERT	01_EDA_FE.ipynb
3. Inteligencia Multimodal (Selección)	Poda de colinealidad Spearman y sondas aleatorias de ruido	02_Feature_selection.ipynb
4. Metodología de Validación y GPU	Purged Time Series CV, WoE Scorecard, Modelos GPU y calibración	03_Model_Training_GPU_and_Benchmark.ipynb
5. Benchmark y Costes (12M y 24M)	Tablas de rendimiento, P&L económico y umbral óptimo τ^*	03_Model_Training_GPU_and_Benchmark.ipynb
5. Contrastes e Intervalos	Tests formales de DeLong, McNemar y Bootstrap 95%	04_Explainability_SHAP_and_Stress_Testing.ipynb
6. Gestión Operativa y Estrés	Curvas Lift, Simulación Monte Carlo (10,000 it.) y Drift PSI/KS	04_Explainability_SHAP_and_Stress_Testing.ipynb
7. Explicabilidad XAI y Regulación	TreeSHAP global, análisis local y cartas de acción adversa	04_Explainability_SHAP_and_Stress_Testing.ipynb
8. Arquitectura de Producción	Microservicio FastAPI, contratos Pydantic y Docker	api/main.py / Dockerfile

1. VISIÓN ESTRATÉGICA, MARCO REGULATORIO Y ASIMETRÍA DEL RIESGO CREDITICIO

1.1. Contexto de negocio: Fragilidad en grandes empresas y destrucción de valor sistémico

La predicción de insolvencia y quiebra corporativa grandes empresas representa uno de los mayores desafíos estratégicos en la gestión del riesgo de crédito. A diferencia del segmento de PYMEs o préstamos minoristas, la insolvencia en compañías cotizadas presenta dos rasgos determinantes para los comités de dirección y riesgos bancarios:

Baja Frecuencia pero Severidad Extrema: La tasa anual de incumplimiento en emisores cotizados es estadísticamente reducida. Sin embargo, la materialización de un solo evento de quiebra desencadena pérdidas patrimoniales multimillonarias.

Efecto Contagio e Interconexión Sistémica: La caída de una gran compañía propaga ondas de choque inmediatas a través de las cadenas de valor sectoriales, los balances interbancarios, los fondos de pensiones y las líneas de crédito sindicado.

Es por esto que contar con un sistema capaz de detectar quiebra o fragilidad financiera futura cobra una especial relevancia en la gestión de riesgos crediticios, permitiendo renegociaciones de deuda y construir provisiones de manera mas eficiente.

1.2. Marco regulatorio prudencial: Basilea III/IV y NIIF 9 / IFRS 9

El desarrollo de este sistema predictivo se inserta en un marco de estricto cumplimiento normativo bancario, condicionado por dos pilares internacionales:

Acuerdos de Basilea (Basilea II, III y Basilea IV): Exigen a las entidades financieras mediante el enfoque de Calificaciones Internas (Internal Ratings-Based, IRB) estimar con rigor cuantitativo la Probabilidad de Incumplimiento (Probability of Default, PD) a un año. Estas probabilidades determinan el colchón de capital regulatorio exigible. Un modelo impreciso o sobreoptimista conlleva requerimientos punitivos de capital por parte del supervisor bancario.

Norma Contable Internacional NIIF 9 / IFRS 9 (Enfoque Expected Credit Loss - ECL): Obliga a provisionar no solo cuando el impago ya se ha producido (pérdida incurrida), sino con un enfoque prospectivo hacia adelante (pérdida esperada). La pérdida crediticia esperada se rige por la identidad financiera:

$$ECL = EAD \times PD \times LGD$$

Donde EAD es la Exposición al Incumplimiento, PD la Probabilidad de Incumplimiento calibrada y LGD la Severidad de la Pérdida (Loss Given Default). (BCBS, 2017) (IASB, 2014)

1.3. Desbalanceo extremo de clases y la falacia del accuracy

Uno de los principales sesgos metodológicos al evaluar modelos de quiebra empresarial consiste en utilizar métricas estadísticas inadecuadas. En una cartera corporativa donde la tasa anual de insolvencia es del 2%, un clasificador trivial que predijera de forma fija "empresa solvente" alcanzaría un 98% de exactitud (Accuracy).

Pese al aparente buen resultado, este modelo resultaría inútil pues ignoraría el 100% de las quiebras. Es aquí donde cobra especial importancia la matriz de confusión y diferentes métricas derivadas.

Tabla 1 Matriz de confusión

	Predicción: Solvente ($\hat{y} = 0$)	Predicción: Quiebra ($\hat{y} = 1$)
Real: Solvente ($y = 0$)	Verdadero Negativo (VN) Crédito concedido a empresa sana. Resultado: Cobro de intereses (Margen NIM).	Falso Positivo (FP) Alerta errónea / Denegación indebida. Resultado: Pérdida de cliente y de margen.
Real: Quiebra ($y = 1$)	Falso Negativo (FN) Quiebra no detectada por el modelo. Resultado: Pérdida del principal del préstamo.	Verdadero Positivo (VP) Quiebra detectada a tiempo. Resultado: Provisión o desinversión preventiva.

A partir de la matriz de confusión, se extraen las cuatro métricas clave para evaluar la solvencia de los modelos:

- **Accuracy (Exactitud):** Porcentaje global de aciertos sobre el total de casos.

- Recall (Sensibilidad): De todas las empresas que realmente quiebran, ¿qué porcentaje logra interceptar el modelo?
- Precisión (Fiabilidad de las Alertas): De cada 100 empresas a las que el modelo cataloga en riesgo de quiebra, cuántas quiebran realmente.
- Specificity (Especificidad): Porcentaje de empresas solventes correctamente identificadas como sanas, garantizando que el flujo comercial de concesión no se bloquee innecesariamente.
- ROC-AUC (Área bajo la Curva ROC): Mide la capacidad global del modelo para distinguir una empresa sana de una en quiebra.
- Su limitación en banca: Como la inmensa mayoría de empresas son solventes (clase mayoritaria), el volumen masivo de empresas sanas hace pasar desapercibidos los errores del modelo. Esto hace que el ROC-AUC se muestre artificialmente optimista (con valores superiores al 0.97) aun cuando el modelo genere un número excesivo de falsas alarmas.
- PR-AUC (Precision-Recall AUC / Average Precision): Evalúa exclusivamente cómo se comporta el modelo frente a la clase crítica: las quiebras.

Mide de forma transparente balance entre cazar las quiebras (Recall) y acertar en las alertas (Precision), sin dejarse desvirtuarse por la multitud de casos sanos. Por este motivo, se adopta como la métrica rectora para seleccionar el mejor modelo para la entidad.

1.4. Modelización de la pérdida asimétrica

Tras aclarar el concepto de la matriz de confusión, ampliamos la idea hacia la modelización de las perdidas. En gestión de riesgos no tiene el mismo impacto económico un falso negativo que un falso positivo.

Coste del Falso Negativo (C_{FN}): Conceder crédito a una empresa que finalmente quiebra. El banco asume la pérdida directa del principal no recuperado.

Coste del Falso Positivo (C_{FP}): Denegar erróneamente un crédito a una empresa solvente por exceso de conservadurismo. El perjuicio no es la pérdida de capital, sino únicamente el coste de oportunidad del margen financiero que se deja de percibir.

Para modelizar esta casuística se ha parametrizado una operación estándar de la siguiente forma:

Exposición al Incumplimiento (EAD): 10,000,000 USD

Severidad de Pérdida (LGD histórica observada del 60%) $C_{FN} = EAD \times LGD = 6,000,000 \text{ USD}$

Margen de Intermediación Neto Bancario (NIM del 2.5%) $C_{FP} = EAD \times NIM = 250,000 \text{ USD}$

$$\text{Razón de Asimetría de Negocio} = \frac{C_{FN}}{C_{FP}} = \frac{6,000,000 \text{ USD}}{250,000 \text{ USD}} = 24$$

Tabla 2 Matriz de Impacto Financiero en la Concesión Crediticia (EAD = \$10M)

	Predicción: Solvente ($\hat{y} = 0$)	Predicción: Quiebra ($\hat{y} = 1$)
Real: Solvente ($y = 0$)	Concesión Exitosa (Acierto) Margen financiero neto: +\$250,000 USD	Falso Positivo (C_{FP}) Coste de oportunidad: -\$250,000 USD
Real: Quiebra ($y = 1$)	Falso Negativo (C_{FN}) Pérdida de principal (LGD 60%): -\$6,000,000 USD	Quiebra Evitada (Acierto Crítico) Pérdida de capital evitada: +\$6,000,000 USD

Cometer un Falso Negativo es 24 veces más costoso que cometer un Falso Positivo. Los umbrales de decisión del modelo deben calibrarse para minimizar esta pérdida monetaria total, priorizando la protección patrimonial de la entidad.

1.5. Objetivos estratégicos del proyecto

Ecosistema de datos multimodal: Integrar más de 340 millones de registros de estados contables XBRL de la SEC EDGAR (2009–2026), precios de mercado bursátil, indicadores macroeconómicos de la Reserva Federal (FRED) y noticias financieras no estructuradas.

Superar las limitaciones de los ratios contables aislados: Extraer señales predictivas avanzadas incorporando la distancia al default de mercado (Merton KMV), regímenes de liquidez latentes (GMM) y señales de estrés en prensa financiera (FinBERT/BERTopic).

Optimización con enfoque en la cuenta de resultados: Entrenar y contrastar una familia completa de algoritmos predictivos en GPU (desde Scorecards regulatorios de Basilea hasta Gradient Boosting y ensamblados Soft Voting), optimizando el umbral operativo bajo la matriz de coste asimétrico de 24x.

Gobernanza y productivización real (MLOps): Dotar al sistema de interpretabilidad regulatoria mediante valores SHAP y generación automática de Cartas de Acción Adversa (conforme a las leyes FCRA y ECOA), desplegando una arquitectura de microservicios en tiempo real con FastAPI respaldada por pruebas de software automáticas.

2. ARQUITECTURA DE INGESTA EFICIENTE, CALIDAD DEL DATO Y GOBERNANZA

2.1. Fuentes de datos y universo de empresas

Para construir un sistema predictivo de quiebras el proyecto combina las siguientes fuentes de datos construyendo un dataset de 108 variables que va de 2009 a 2026.

- Estados financieros de la SEC EDGAR: Ingesta censal de más de 343.6 millones de hechos numéricos contables procedentes de los informes anuales (10-K) y trimestrales (10-Q) de empresas en EE.UU. A través del identificador legal único CIK (Central Index Key), se neutralizan los problemas derivados de cambios de nombre, fusiones o fluctuaciones en el ticker bursátil. (SEC, 2024)
- Cotizaciones bursátiles históricas (Yahoo Finance): Precios diarios de cierre, volumen negociado y capitalización bursátil. Se rescató el historial completo de cotizaciones de compañías liquidadas o expulsadas de bolsa (delisted). Con ello se erradica el Sesgo de Supervivencia un error metodológico habitual que infla artificialmente la solvencia aparente de las carteras al evaluar únicamente a las empresas que sobrevivieron hasta hoy.
- Magnitudes macroeconómicas oficiales de la Reserva Federal (FRED): Series temporales de tipos oficiales, curva de tipos (diferencial 10Y-2Y), PIB real, desempleo e inflación (IPC). (Federal Reserve Bank of St. Louis, 2024)
- Noticias financieras: Ingesta masiva de más de 13.1 millones de noticias y titulares financieros en bruto (3.58 millones consolidados para el universo de análisis) combinando dataset FNSPID de huggingface y completando para años recientes a través de APIs de noticias. Esta fuente permite incorporar señales valiosas mediante procesamiento de lenguaje natural.

2.2. Arquitectura de ingesta columnar con DuckDB

Para trabajar con un dataset masivo de estas características se ha optado por la adopción de duckDB (Raasveldt y Mühleisen, 2019) y el formato parquet. DuckDB procesa los 343.6M de registros contables directamente sobre disco local sin necesidad de infraestructura en la nube y ejecuta la extracción relacional y el filtrado. Esto permitió consolidar un Dataset de 404,853 presentaciones empresa-trimestre correspondientes a 15,098 CIKs (empresas) únicos.

Se redujo el peso del dataset de 45gb a 1.1gb gracias al filtrado de etiquetas contables y metadatos redundantes, tipado estricto columnar en DuckDB, asignación de tipos de datos numéricos de bajo consumo en memoria, y compresión en parquet. Esto ha permitido ejecutar consultas sobre una estación de trabajo convencional.

2.3. Formalización de la variable objetivo de insolvencia y su prevalencia

En el universo de empresas cotizadas, la declaración judicial formal de quiebra (Chapter 11 de la SEC) suele llegar con meses de retraso respecto a la insolvencia operativa real de la firma. Para proporcionar una alerta verdaderamente útil, la variable objetivo a 12 meses (target_bankrupt_12m) se formaliza como un evento multicriterio de insolvencia técnica y estrés severo activado si en los siguientes 365 días la compañía cumple cualquiera de las siguientes condiciones:

- Insolvencia Contable Extrema: Patrimonio neto negativo (Stockholders' Equity ≤ 0) o situación de quiebra técnica donde el pasivo exigible total supera a los activos totales.

- Estrés Crítico de Mercado: Distancia al Incumplimiento del modelo estructural de Merton KMV inferior a 0.5 ($DtD \leq 0.5$), indicando que el valor bursátil de los activos ha colapsado hacia el nivel de su deuda.
- Asfixia de Liquidez y Cobertura Operativa: Fondo de maniobra negativo ($Working\ Capital < 0$) combinado con pérdidas netas recurrentes o incapacidad para cubrir los gastos por intereses con el beneficio operativo.
- Evento Concursal Legal: Presentación formal ante la SEC de concurso de acreedores (Chapter 11), liquidación judicial (Chapter 7) o delisting bursátil por insolvencia (Form 8-K ítem 1.03).

Del mismo modo, aunque de manera secundaria se ha incluido la misma variable objetivo pero con horizonte temporal a 24 meses.

Bajo esta definición el dataset presenta el siguiente desbalanceo:




Tabla 3 Resumen dataset

Ventana temporal	2009 – marzo 2026	17 años de historia: ciclo expansivo, shock COVID-19 y subida de tipos Fed 2022–2024.
Entidades Analizadas	15,098 CIKs únicos	Cobertura censal del S&P 500 y emisores cotizados en NYSE, NASDAQ y OTC.
Presentaciones	393,331 observaciones	Informes anuales 10-K y trimestrales 10-Q deduplicados a nivel empresa-período.
Registros Ingestados	343.6 millones	Volumen censal de hechos contables procesados y consolidados mediante DuckDB.
Corpus de Noticias	13.16M (3.58M en panel)	Artículos financieros para extracción de sentimiento (FinBERT) y tópicos (BERTopic).
Variable Objetivo	target_bankrupt_12m	Insolvencia técnica con horizonte a 12 meses.
Prevalencia del Target	12.07% (47,462 casos)	Tasa observada de insolvencia técnica sobre el censo de 393,331 registros.

Durante la realización del trabajo se detectó una anomalía recurrente en los datos, tras solicitar concurso de acreedores (chapter 11 de la SEC) existe la posibilidad de que una empresa continúe presentando balances en liquidación durante meses. Un modelo que prediga que una empresa que quebró hace 3 meses va a seguir en quiebra carece de valor preventivo. El sistema se validó separando las Transiciones Puras (empresas que se degradan de solventes a insolventes a 12 meses vista) frente a la Persistencia Terminal (compañías ya en proceso concursal), demostrando que la capacidad de anticipación real supera el 96% de captura en transiciones puras.

2.4. Gobernanza del dato: Cero Look-Ahead Bias, imputación Sectorial y atípicos

Conforme a las directrices de gobernanza de modelos bancarios (Guía Federal Reserve SR 11-7 (2011) y requerimientos EBA (2017)), se implementaron tres controles de calidad:

- Garantía de integridad temporal (Zero Look-Ahead Bias): En finanzas, la fecha de cierre del balance (period_date, ej. 31 de diciembre) no coincide con su disponibilidad pública: las empresas tardan entre 30 y 90 días en auditar y presentar sus cuentas ante la SEC (filed_date). El sistema bloqueó cualquier alineamiento temporal sobre la fecha de cierre contable, indexando toda la información a la fecha de publicación oficial (period_date ≤ filed_date). Se

garantiza un 0% de fuga temporal, replicando la información real de la que disponía el analista de crédito en cada fecha histórica.

- Tratamiento de nulos mediante imputación jerárquica sectorial: En lugar de descartar balances incompletos lo que eliminaría sectores completos como empresas de software sin existencias, se aplicó una imputación jerárquica por código industrial (SIC) utilizando la mediana del sector para ese mismo ejercicio fiscal. Esto asegura una matriz final 100% analizable y sin sesgos de selección.
- Detección de atípicos con isolation forest: Para corregir inconsistencias de escala en el reporte XBRL (errores de factor multiplicador en unidades vs miles), se utilizó el algoritmo no supervisado Isolation Forest, aislando de forma objetiva el 3% de registros incoherentes sin distorsionar los casos reales de estrés financiero.

3. INTELIGENCIA MULTIMODAL: DE LA CONTABILIDAD TRADICIONAL A LA INTELIGENCIA ARTIFICIAL

3.1. Ratios contables clásicos y modelo estructural de Merton KMV

En el análisis convencional de riesgo crediticio se fundamenta en ratios financieros derivados de los balances como el Fondo de maniobra, apalancamiento financiero, rentabilidad económica y ratios Altman Z-Score (indicador sintético que combina liquidez, solvencia y rentabilidad acumulada). Aunque estos ratios presentan información muy valiosa presentan una debilidad, informan del estado de la compañía al cierre del trimestre anterior, son indicadores estáticos en el tiempo. (Altman, 1968)

Para atajar este problema se implementa el modelo estructural de Merton (1974) que consiste en lo siguiente:

El modelo trata el valor bursátil del capital de la empresa como una opción de compra sobre el valor total de sus activos, donde el precio de ejercicio es el valor nominal de su deuda con vencimiento a un año. Si los activos caen por debajo de la deuda, la empresa entra en quiebra económica. A través de la resolución numérica de las ecuaciones de Black-Scholes (1973), se estima el valor no observable de los activos y su volatilidad real. La variable `merton_distance_to_default` mide cuántas desviaciones típicas separan a los activos corporativos del umbral de quiebra. Mientras que el balance trimestral tarda semanas en reflejar el deterioro, una caída abrupta en la distancia al default de Merton alerta de forma inmediata sobre la asfixia financiera percibida por el mercado.

3.2. Detección no supervisada de regímenes económicos y arquetipos corporativos con GMM

Las empresas no operan en el vacío: una compañía con alto endeudamiento puede sobrevivir holgadamente con tipos de interés al 0% y entrar en liquidación en un entorno de endurecimiento monetario. Para capturar estas interacciones no lineales sin imponer reglas manuales arbitrarias, se entrenaron modelos de mezcla gaussiana (Gaussian Mixture Models – GMM) (Dempster, Laird y Rubin, 1977) no supervisados optimizados por el criterio de información bayesiano (BIC) y se obtuvieron los siguientes resultados:

Tabla 4 Resumen GMM

Clúster	Tipo	Características diferenciales	Tasa insolvencia
Régimen 0	Expansión económica	Crecimiento PIB +3.2%, curva de tipos normal (+0.71%)	12.04%
Régimen 1	Endurecimiento FED	Tipos al 4.34%, curva invertida (-0.07%), fin de ciclo.	9.45%
Régimen 2	Crisis y estrés financiero	Desempleo al 7.5%, tipos al 0.10%, shock de liquidez.	13.32%
Arquetipo 0	Micro-cap distress	Pérdidas recurrentes, liquidez mínima. Concentra el 85% de quiebras.	31.61%
Arquetipo 1	Mid-Cap con liquidez	Empresas medianas con márgenes estrechos con fondo de maniobra positivo.	3.85%
Arquetipo 2	Large-cap solvente	Amplia solvencia en balance y generación de caja	1.82%
Arquetipo 3	Mega-cap	Grandes empresas cotizadas, Apple, Microsoft...	0.99%

3.3. Minería de textos financieros y análisis de sentimiento con FinBERT y BERTopic

La prensa financiera publica noticias sobre impagos de bonos, problemas legales y despidos masivos entre otros meses antes de que la empresa reconozca deterioro financiero en sus balances. Es por esto que analizar textos financieros puede aportar señales valiosas en la detección de riesgos. En este trabajo se ha realizado de la siguiente forma:

3.3.1. Sentimiento financiero contextual con FinBERT

Para procesar más de 3.5 millones de noticias financieras en inglés, se utilizó el modelo Transformer FinBERT (Araci, 2019) (Devlin et al., 2019), preentrenado específicamente sobre corpus financiero, entrando un poco en detalle técnico:

Optimización de cómputo ($L=128$): Un análisis exploratorio mostró que el 99.78% de los titulares y resúmenes financieros tienen menos de 128 palabras. Fijar la longitud máxima en $L=128$ en lugar de los 512 tokens estándar de BERT permitió un ahorro de cómputo del 93.75% en GPU, garantizando una inferencia a más de 4,500 titulares por segundo, y que se traduce en un menor coste.

Ponderación por decaimiento temporal ($t_{1/2}=14$ días): Una noticia pierde relevancia rápidamente (información ya descontada). Se aplicó una función de descuento exponencial con una vida media de dos semanas: el impacto de una noticia negativa se diluye si no se confirma con nuevos eventos adversos.

3.3.2. Extracción de tópicos de estrés con BERTopic

Con el fin de enriquecer aún más el análisis, mediante modelado temático no supervisado guiado (Guided BERTopic) (Grootendorst, 2022), el sistema extrae la intensidad con la que una compañía es mencionada en tres categorías críticas de riesgo:

Incumplimientos de deuda y covenants (`distress_default_intensity`): Ruptura de acuerdos bancarios, rebajas de calificación crediticia a grado especulativo (junk) o impagos de intereses.

Procedimiento concursal formal (`distress_bankruptcy_intensity`): Menciones explícitas a liquidación, administración judicial o preparación de concurso de acreedores.

Litigios severos y fraude contable (`distress_litigation_intensity`): Investigaciones de la SEC o el Departamento de Justicia, demandas colectivas o reformulación forzosa de balances (`restatements`).

3.3.3. La señal del silencio mediático (`media_silence_months_count`)

Un indicador introducido en el sistema es la métrica de silencio mediático, cuando una compañía que habitualmente genera noticias deja de ser cubierta por los analistas y la prensa económica, puede aportar señales valiosas, por ejemplo, anticipar un proceso de abandono institucional y falta de transparencia previa al colapso financiero.

3.4. Selección de variables

El conjunto original de datos superaba las 108 variables, se hace necesario reducir dimensionalidad ya que perjudica interpretabilidad regulatoria del modelo y puede aumentar el sobreajuste. El proceso de reducción de dimensionalidad se ha ejecutado en tres etapas:

- Eliminación de variables de manera heurística y fundamentada, de esta manera se reducen las variables hasta 52. En esta fase se encuentra metadatos administrativos, variables redundantes y otras decisiones que han sido fundamentadas en el notebook 01.
- Sondas de ruido estocástico (Random Probes): Se inyectaron dos variables de ruido aleatorio uniforme en modelos CatBoost (el mejor en ese momento con las 52 variables) en GPU; todas aquellas características cuyo poder predictivo fue inferior al del ruido puro fueron eliminadas. Tras este paso el dataset se redujo a 37 variables.
- Poda estricta de colinealidad de Spearman (1904) ($|r| \geq 0.75$): Se identificaron y eliminaron 16 variables altamente redundantes (por ejemplo, pasivos totales frente a pasivos corrientes, o el PIB en niveles frente a tasas de crecimiento interanuales). Este paso redujo dimensionalidad a 21 variables.

Tabla 5 21 variables del sistema predictivo

Tipo	Número de variables	Naturaleza
Contabilidad SEC	9	Beneficios, working capital, activos, lag de publicación y otras magnitudes contables
Mercado y Merton KMV	3	Distancia al default (merton_distance_to_default), precio de cierre de mercado, capitalización
Entorno macroeconómico	6	Regímenes GMM, inflación, tipo de interés y crecimiento PIB
Textos y prensa (NLP)	3	Sentimiento con decaimiento a 30 días, intensidad de tópicos de estrés concursal BERTopic, sentimiento medio de mercado y conteo de silencio mediático.

4. METODOLOGÍA DE VALIDACIÓN Y MODELADO PREDICTIVO EN GPU

4.1. Esquema de validación temporal: 5-fold purged group time series cross-validation

En la modelización del riesgo de crédito corporativo, el diseño del esquema de validación determina si el sistema funcionará de forma fiable en el mundo real o si sufrirá de sobreajuste.

4.1.1. La invalidez de la validación cruzada aleatoria tradicional

En problemas estándar de ciencia de datos es habitual recurrir a una partición aleatoria (K-fold cross-validation). En finanzas corporativas, esta práctica constituye un fallo metodológico severo por dos motivos:

- Fuga temporal (look-ahead bias): Al mezclar aleatoriamente trimestres, el algoritmo podría utilizar datos de 2021 para "predecir" la solvencia de una empresa en 2015. En la realidad bancaria, el futuro jamás está disponible para predecir el pasado.
- Fuga transversal entre entidades (panel cross-talk): Si el balance del primer trimestre de una empresa está en el conjunto de entrenamiento y el segundo trimestre en el de prueba, el modelo aprende la identidad intrínseca de la firma en lugar de patrones generales de quiebra.

Metodología expuesta por Lopez de Prado (2018)

4.1.2. El protocolo de validación implementado

Para asegurar que no se comenten estos errores se ha diseñado este protocolo:

- Aislamiento por entidad (group_col = 'cik'): Todas las observaciones históricas de un mismo emisor se asignan exclusivamente al conjunto de entrenamiento o al de validación en cada iteración, impidiendo cualquier filtración de identidad.
- Ventana temporal expansiva (rolling forward): El conjunto de entrenamiento precede estrictamente en el tiempo al conjunto de prueba, evaluando siempre el modelo hacia adelante.
- Ventana de seguridad (purging de 365 días): Dado que la variable objetivo (target_bankrupt_12m) evalúa un horizonte prospectivo a un año vista, se elimina una franja de seguridad de 365 días (730 para la variable objetivo secundaria a 24 meses) entre el final del entrenamiento y el inicio de la prueba. Esto garantiza que ningún evento futuro solape con los predictores de entrada.

Tabla 6 Folds de validación

Fold	Periodo Entrenamiento (Train)	Obs. Train (Quiebras)	Ventana Purga	Periodo de Prueba	Obs. Test (CIKs)	Quiebras Test (% Prevalencia)
Fold 1	15/04/2009 – 27/07/2012	38,221 (4,000)	367 días (2012–2013)	29/07/2013 – 14/05/2015	54,488 (8.255)	7,649 (14.04%)
Fold 2	15/04/2009 – 14/05/2015	122,261 (15,916)	365 días (2015–2016)	13/05/2016 – 02/03/2018	43,303 (7.122)	6,032 (13.93%)
Fold 3	15/04/2009 – 02/03/2018	192,367 (25,777)	367 días (2018–2019)	04/03/2019 – 16/12/2020	42,679 (6.562)	5,183 (12.14%)
Fold 4	15/04/2009 – 16/12/2020	258,954 (34,064)	365 días (2020–2021)	16/12/2021 – 05/10/2023	45,542 (7,209)	4,458 (9.79%)
Fold 5	15/04/2009 – 05/10/2023	329,620 (41,225)	365 días (2023–2024)	04/10/2024 – 31/07/2026	40,287 (6,464)	3,713 (9.22%)

4.2. Portafolio de modelos evaluados: del estándar regulatorio a los modelos avanzados

Para encontrar el modelo óptimo y obtener los mejores resultados, se contrastó una familia diversa de arquitecturas, desde los enfoques lineales tradicionales hasta algoritmos de ensamblado:

4.2.1. Scorecard regulatorio de crédito Basilea (Weight of Evidence - WoE)

Constituye el estándar canónico en la banca tradicional bajo Basilea II/III:

Transforma cada variable en tramos discretos mediante agrupación monótona, asignando un peso de evidencia (Weight of Evidence, WoE) según la tasa de morosidad observada en cada rango.

Convierte las probabilidades en una escala de puntuación crediticia estándar de 300 a 850 puntos, análoga a los modelos FICO corporativos.

(Siddiqi, 2017) (Navas-Palencia, 2020)

Ventaja de negocio: Interpretabilidad y auditabilidad absolutas. Los analistas de riesgo pueden ver con exactitud cuántos puntos resta cada ratio financiero a la empresa.

4.2.2. Regresión logística regularizada

Línea base lineal clásica econométrica, es sencilla y altamente explicable lo que aporta una gran ventaja frente al regulador, sin embargo, no suele alcanzar los niveles de precisión de los modelos de machine learning.

4.2.3. Modelos de árboles de decisión y gradient boosting en GPU

Los modelos basados en árboles capturan de forma nativa relaciones no lineales e interacciones complejas entre ratios contables, sentimiento de prensa y regímenes macroeconómicos:

- Random Forest (Breiman (2001): Ensamblado por bagging de árboles independientes; destaca por su resistencia al ruido y por alcanzar la mayor precisión operativa individual (45,90%).
- LightGBM (Ke et al., 2017): Boosting basado en histogramas discretos; sobresale por su mínima latencia de inferencia y una elevada captura de quiebras (97,50% de recall).
- XGBoost (Chen y Guestrin, 2016)): Optimiza gradientes de segundo orden con control de complejidad; se consolida como el modelo líder del benchmark, obteniendo el menor coste asimétrico total (2,380M USD) y el mayor PR-AUC (0.8551).
- CatBoost GPU (Prokhorenkova et al., 2018): Emplea divisiones oblivious simétricas que mitigan el sobreajuste ante distribuciones asimétricas, capturando el 97,05% de las insolvencias

4.2.4. Soft voting ensemble

En lugar de depender de un único algoritmo, se construyó un comité de modelos que promedia las probabilidades estimadas por los cuatro algoritmos de árboles (25% LightGBM, 25% Random Forest, 25% CatBoost y 25% XGBoost), se ha elegido un reparto equitativo en el peso de la elección ya que el PR-AUC de cada uno de ellos era prácticamente idéntico.

4.2.5. Red neuronal profunda con pérdida asimétrica (PyTorch MLP)

Para evaluar el potencial del deep learning, se diseñó una red neuronal con una función de pérdida personalizada. Esta arquitectura fue programada para optimizar directamente la asimetría del negocio bancario durante la retropropagación, penalizando cada falso negativo con un factor 24 veces superior al de un falso positivo.

4.2.6. Línea base tradicional (Altman Z-Score y Merton DtD sin machine learning)

Modelo de referencia sin aprendizaje automático, utilizado para cuantificar con precisión el valor añadido real que aporta la inteligencia multimodal frente a los enfoques del siglo XX.

4.3. Aceleración computacional en GPU y optimización bayesiana de hiperparámetros

4.3.1. Aceleración de cómputo en hardware GPU

El entrenamiento y validación de múltiples familias de algoritmos sobre una matriz de 393,331 presentaciones a lo largo de 5 folds temporales supondría demasiadas horas de cómputo secuencial en CPU.

Esta barrera se ha superado mediante la aceleración por hardware en GPU con núcleos CUDA y procesamiento tensorial, el tiempo de entrenamiento se redujo en más de un 88%, completando la validación cruzada completa en menos de 15 minutos.

Esta velocidad permitió iterar y reentrenar los modelos ante pruebas, cambios de variables y más procesos durante el desarrollo del trabajo.

4.3.2. Optimización bayesiana con Optuna

La calibración manual de hiperparámetros suele ser subóptima y arbitraria. En este trabajo se utilizó el marco de optimización bayesiana Optuna mediante el muestreador TPE (Akiba et al., 2019):

- En lugar de maximizar métricas simétricas estándar, la optimización se basó en buscar la minimización del coste de pérdidas asimétricas en dólares ($C_{FN} = 24 \times C_{FP}$)
- Parámetros calibrados: umbral de decisión, Profundidad máxima de los árboles, tasa de aprendizaje (learning rate), regularización L1/L2 y ratio de submuestreo de variables y filas por árbol.

4.4. Calibración de probabilidades bajo la normativa contable IFRS 9

En el marco de la normativa contable internacional NIIF 9 / IFRS 9, las entidades financieras deben calcular las provisiones por pérdida crediticia esperada multiplicando la exposición por la severidad y la probabilidad de incumplimiento ($ECL = EAD \times PD \times LGD$).

4.4.1. La necesidad de calibrar las salidas de machine learning

Los algoritmos de gradient boosting destacan por su capacidad para ordenar el riesgo (discriminación), pero sus salidas de probabilidad bruta pueden estar distorsionadas, acumulando predicciones cerca de los extremos (0 y 1).

Si un modelo asigna una probabilidad estimada del 20% a un grupo de préstamos, pero realmente solo quiebra el 5%, el banco sobreprovisionaría capital de forma innecesaria, encareciendo el crédito y perdiendo clientes frente a sus competidores.


4.4.2. Técnicas de calibración y resultados empíricos

Se evaluaron dos técnicas de ajuste probabilístico supervisado sobre los conjuntos de validación:

- Platt scaling (sigmoide logística): Ajuste paramétrico unidimensional que mapea las puntuaciones del modelo a una curva logística.
- Isotonic Regression: Ajuste no paramétrico monótono que corrige la probabilidad preservando estrictamente el orden relativo de los emisores.

Platt scaling mejora del 28.83% en el Brier score (1950): El error cuadrático medio probabilístico (Brier score) se redujo desde 0.0462 en el modelo sin calibrar hasta 0.0329, certificando una alta pureza en las probabilidades estimadas.

Test de Hosmer-Lemeshow (2000): La evaluación en 10 deciles de riesgo evidencia una reducción del 88.53% en la distorsión cuadrática acumulada, contrayendo el estadístico de Hosmer-Lemeshow desde $H = 9.753,78$ en el modelo crudo hasta $H = 1.118,63$ en el calibrado. Si bien el contraste formal arroja $p < 0.001$ debido a la sensibilidad y extrema potencia estadística del test chi-cuadrado ante tamaños muestrales masivos.



5. RESULTADOS DEL BENCHMARK, FIABILIDAD PROBABILÍSTICA Y RIGOR ESTADÍSTICO

5.1. Resultados del benchmark

Se han evaluado diferentes modelos sobre el panel de 393,331 presentaciones de la SEC con el fin de optimizar los costes para un banco. Conforme a la política de riesgo bancario, los modelos se ordenan estrictamente de menor a mayor coste total, penalizando el error asimétrico donde cometer un falso negativo cuesta 24 veces más que un falso positivo ($C_{FN} = 24 \times C_{FP}$).

Tabla 7 Resultados del benchmark de modelos a 12 meses (media 5 folds)

Posición	Algoritmo / Modelo	Umbral (τ^*)	Recall (%)	Precision (%)	Specificity (%)	Falsos Neg. (FN)	Falsos Pos. (FP)	PR-AUC	ROC-AUC	Coste Total (millones USD)	P&L Neto (millones USD)
1	XGBoost	0.158	97.49%	44.98%	84.14%	132	6,353	0.8551	0.9763	2,380.25	+37,644.50
2	LightGBM	0.224	97.50%	44.82%	83.86%	127	6,484	0.8501	0.9759	2,383.00	+37,633.00
3	Random Forest	0.182	97.22%	45.90%	84.78%	148	6,089	0.8450	0.9751	2,410.25	+37,578.50
4	Ensemble (Soft Voting)	0.220	97.13%	45.20%	84.34%	144	6,275	0.8449	0.9751	2,432.75	+37,533.50
5	CatBoost	0.038	97.05%	43.90%	83.43%	153	6,638	0.8462	0.9744	2,577.50	+37,250.00
6	Logistic Regression	0.170	96.96%	22.36%	49.79%	141	20,873	0.4193	0.7964	6,064.25	+30,270.50
7	PyTorch MLP	0.166	77.36%	18.18%	63.68%	1,657	13,793	0.4211	0.7568	13,390.25	+15,624.50

- **Liderazgo de XGBoost:** XGBoost se posiciona como el modelo campeón del estudio a 12 meses. Alcanza el mayor PR-AUC del benchmark (0.8551) y la máxima rentabilidad para la entidad, reduciendo el coste total medio por cohorte a 2,380.25 millones USD con un P&L neto positivo de +37,644.50 millones USD.
- **LightGBM:** Se sitúa prácticamente en empate técnico con el líder (coste de 2,383.00 millones USD, una diferencia de apenas 2.75 millones USD). Logra el menor número de fallos críticos de todo el estudio, minimizando las quiebras no detectadas a solo 127 falsos negativos (97.50% de recall).
- **Random Forest:** ofrece la mayor precisión del benchmark (45.90%) y la mayor especificidad (84.78%), reduciendo las falsas alarmas crediticias a 6,089 falsos positivos y situando su coste en 2,410.25 millones USD.
- **Soft Voting Ensemble:** No consigue mejorar a los modelos de arboles.
- **Frente a la regresión logística regularizada** (coste de 6,064.25 millones USD), XGBoost genera un ahorro directo de 3,684.00 millones USD (-60.7%), evitando más de 14,520 denegaciones injustificadas a empresas solventes (los falsos positivos caen de 20,873 a 6,353).

- La red neuronal PyTorch MLP con pérdida asimétrica ha resultado ser muy ineficiente no logrando superar a la regresión logística. El ahorro de XGBoost frente a este modelo asciende a 11,010.00 millones USD (-82.2%).

Tabla 8 Resultados del benchmark de modelos a 24 meses (media 5 folds)

Posición	Algoritmo / Modelo	Umbral (τ^*)	Recall (%)	Precision (%)	Specificity (%)	Falsos Neg. (FN)	Falsos Pos. (FP)	PR-AUC	ROC-AUC	Coste Total (millones USD)	P&L Neto (millones USD)
1	LightGBM	0.256	97.21%	43.19%	78.89%	72	3,651	0.8520	0.9683	1,344.75	+18,193.25
2	Random Forest	0.202	96.72%	45.38%	80.75%	87	3,303	0.8468	0.9674	1,347.75	+18,193.00
3	XGBoost	0.184	97.13%	43.32%	79.99%	82	3,426	0.8526	0.9682	1,348.50	+18,185.50
4	Ensemble (Soft Voting)	0.258	96.82%	43.87%	79.48%	81	3,534	0.8443	0.9672	1,369.50	+18,143.75
5	CatBoost	0.082	96.15%	45.55%	80.39%	98	3,410	0.8503	0.9665	1,440.50	+18,001.50
6	Logistic Regression	0.224	95.80%	27.17%	53.73%	95	8,508	0.4859	0.8078	2,697.00	+15,488.50
7	PyTorch MLP	0.186	71.33%	17.96%	59.76%	1,072	6,354	0.4173	0.6819	8,020.50	+4,841.75

(El coste y P&L es menor porque se evalúan menos empresas al cambiar el horizonte temporal)

- Liderazgo de LightGBM a 24 meses: Encabeza el horizonte bienal con el menor coste (1,344.75 millones USD) y un PR-AUC de 0.8520, capturando el 97.21% de las insolvencias con dos años de antelación, seguido a mínima distancia por Random Forest (1,347.75 millones) y XGBoost (1,348.50 millones).
- Robustez frente al horizonte de 12 meses: A pesar de duplicar la purga temporal a 730 días para impedir cualquier fuga, la capacidad discriminativa no sufre degradación (PR-AUC de 0.8520 en 24M vs. 0.8501 en 12M)
- Jerarquía de modelos intacta: Se reproduce la superioridad del gradient boosting, reduciendo los costes en más de un -50% respecto a la regresión logística (2,697.00 millones USD) y en un -83% frente a la red neuronal PyTorch (8,020.50 millones USD).

5.2. Contrastes estadísticos formales de superioridad: DeLong y McNemar

En auditorías de modelos bancarios (conforme a la Guía Federal Reserve SR 11-7), no es suficiente afirmar que un modelo tiene un número superior a otro; es obligatorio certificar mediante pruebas de hipótesis formales que la diferencia no es producto del azar o de fluctuaciones de la muestra.

5.2.1. Test no paramétrico de DeLong para comparación de curvas ROC-AUC

El test de DeLong (1988), ejecutado mediante el algoritmo rápido de Sun & Xu (2014) en complejidad $O(N \log N)$, evalúa si las diferencias entre las áreas bajo la curva ROC de modelos correlacionados son estadísticamente significativas:

Tabla 9 Resultados de los contrastes pareados del test de DeLong (1998)

Comparación de Modelos	ROC-AUC (M_1)	ROC-AUC (M_2)	Diferencia (ΔAUC)	Estadístico Z	p-valor	Significatividad ($\alpha = 0.05$)
XGBoost (12M) vs. Altman & Merton	0.9752	0.8953	+0.0799	62.740	< 0.0001	Sí ($p < 0.001$)
XGBoost (12M) vs. Scorecard Basilea (WoE)	0.9752	0.9603	+0.0149	28.019	< 0.0001	Sí ($p < 0.001$)
XGBoost (12M) vs. LightGBM (12M)	0.9752	0.9752	+0.0001	0.374	0.7087	NO ($p > 0.001$)
XGBoost (12M) vs. CatBoost (12M)	0.9752	0.9698	+0.0054	12.798	< 0.0001	Sí ($p < 0.001$)

Se rechaza categóricamente la hipótesis nula de igualdad para los contrastes contra los enfoques tradicionales y catboost estableciendo formalmente la superioridad discriminativa de XGBoost. Como se comentó en el punto anterior existía un empate técnico entre XGBoost y LightGBM que se confirma en este test.

5.2.2. Test de McNemar con corrección de continuidad de Edwards

Mientras que DeLong compara la ordenación continua de probabilidades, el test de McNemar (1947) con corrección de continuidad (Edwards, 1948) analiza las discrepancias reales de clasificación (aciertos y errores discordantes) sobre el umbral de decisión operativo. Esto permite contrastar si un modelo comete significativamente menos fallos que otro.

Comparación de Modelos (M_1 vs. M_2)	Casos b (M_1 acierta, M_2 falla)	Casos c (M_1 falla, M_2 acierta)	Ratio de Aciertos (b/c)	Estadístico χ^2	p -valor	Significatividad ($\alpha = 0.05$)
XGBoost vs. Scorecard Basilea (WoE)	15,946	1,967	8.11 a 1	10,907.41	< 0.0001	Sí ($p < 0.001$)
XGBoost vs. Baseline Altman / Merton	6,105	10,929	1 a 1.79	1,365.58	< 0.0001	Sí ($p < 0.001$)

XGBoost acierta en 15,946 expedientes en los que el Scorecard se equivoca, frente a solo 1,967 casos en sentido inverso.

Un ratio de 8.11 a 1 a favor de XGBoost, con un estadístico de $\chi^2 = 10,907.41$ ($p < 0.0001$). Se rechaza categóricamente la hipótesis nula de homogeneidad entre modelos, confirmando que la incorporación de relaciones no lineales reduce sustancialmente los errores reales de admisión crediticia frente al estándar lineal bancario.

En contraposición el contraste contra el modelo Altman & Merton el ratio es a favor de este último. Aunque a priori se pueda interpretar que XGBoost es inferior hay que tener en cuenta que este test es simétrico, pondera de la misma manera falsos positivos y falsos negativos y como ya se ha explicado anteriormente, en el contexto de gestión de riesgos bancarios la matriz de pérdidas (errores) es asimétrica por lo que la aparente ventaja de Altman & Merton se desvanece. El test es útil para confirmar que ambos modelos predicen de manera significativamente diferente.

5.3. Intervalos de confianza empíricos mediante remuestreo bootstrap al 95%

Para comprobar la estabilidad de los resultados ante perturbaciones de mercado sin asumir normalidad en las colas, se ejecutó un remuestreo Bootstrap (Efron y Tibshirani, 1994) estratificado con $B=1,000$ réplicas independientes.

Tabla 10 Intervalos de confianza bootstrap al 95% sobre PR-AUC y ROC-AUC

Modelo	Métrica Evaluada	Media Bootstrap	Error Estándar (σ)	Límite Inferior (2.5%)	Límite Superior (97.5%)	Intervalo de Confianza al 95%
XGBoost	PR-AUC	0.8403	0.0036	0.8334	0.8476	[0.8334 – 0.8476]
XGBoost	ROC-AUC	0.9752	0.0006	0.9740	0.9763	[0.9740 – 0.9763]
XGBoost	F2-Score	0.7941	0.0026	0.7891	0.7992	[0.7891 – 0.7992]
Scorecard Basilea (WoE)	PR-AUC	0.7696	0.0044	0.7611	0.7784	[0.7611 – 0.7784]
Scorecard Basilea (WoE)	ROC-AUC	0.9603	0.0009	0.9585	0.9619	[0.9585 – 0.9619]
Scorecard Basilea (WoE)	F2-Score	0.7262	0.0025	0.7212	0.7311	[0.7212 – 0.7311]

Como se observa en la tabla, el intervalo inferior de XGBoost (PR-AUC > 0.8334) se sitúa a más de 5 puntos porcentuales de distancia del límite superior del scorecard regulatorio tradicional (0.7784). No existe solapamiento entre las distribuciones al 95% de confianza, lo que confirma que la ganancia de poder predictivo es estructural y robusta ante cualquier remuestreo de la cartera.

5.4. Optimización del umbral óptimo de corte bajo costes asimétricos

Un aspecto crucial para la puesta en producción del modelo es la determinación del umbral de decisión operativo τ^* :

- Dado que un falso negativo cuesta 24 veces más que un falso positivo, la teoría de decisión bayesiana establece que el umbral analítico que minimiza las pérdidas monetarias se sitúa en: $\tau^* \approx \frac{C_{FP}}{C_{FP}+C_{FN}} = \frac{1}{1+24} = \frac{1}{25} = 0.04$
- Conviene subrayar que la determinación de τ^* no responde únicamente a la asimetría monetaria de los costes, sino también al desbalanceo de clases (prevalencia de quiebra del 12.07%) y a la curtosis extrema de las variables financieras. Los diferentes algoritmos atajan el problema de diferentes maneras y ofrecen resultados distintos, mientras que CatBoost preserva una escala cercana al óptimo bayesiano teórico ($\tau^* = 0.038$), modelos como XGBoost y LightGBM desplazan su umbral eficiente hacia la franja de 0.158 a 0.224 para neutralizar el desbalanceo sin disparar las falsas alarmas.

- Operar en esta franja de umbrales garantiza capturar más del 97% de las insolvencias reales y manteniendo una especificidad del 84% lo que resulta en protección ante pérdidas sin abandonar el flujo comercial de crédito

6. GESTIÓN OPERATIVA DEL RIESGO, PRUEBAS DE ESTRÉS Y MONITORIZACIÓN DE DERIVA

6.1. Concentración operativa del riesgo: curvas de lift y ganancia acumulada


En la práctica bancaria diaria, los equipos de analistas de riesgos cuentan con recursos limitados, resulta inviable auditar a fondo cientos de miles de expedientes corporativos al año.

Una vez cuantificado en los capítulos precedentes el ahorro económico del modelo, el análisis mediante curvas de ganancia acumulada y curvas de lift permite diseñar la política operativa de triaje y priorización de la entidad:

- Concentración del riesgo en el decil superior (top 10%): Al ordenar de menor a mayor solvencia según la probabilidad predicha por el modelo, el 10% de empresas con peor calificación crediticia concentra el 79.53% de todas las insolvencias reales del mercado.
- Factor de lift de 7.95x: Seleccionar a los emisores del decil de mayor riesgo es 7.95 veces más eficaz para detectar insolvencias que realizar una inspección aleatoria o proporcional de la cartera.
- Cobertura en el top 20%: Al auditar conjuntamente los dos primeros deciles, el departamento de riesgos intercepta de forma preventiva más del 93.89% de todas las quiebras.

Tabla 11 Ejemplo de política de triaje bancario y priorización por deciles de riesgo (XGBoost)

Decil de Riesgo	Porcentaje de Cartera Acumulado	Captura Acumulada de Quiebras	Factor de Lift	Ejemplo de Política Operativa Bancaria
Decil 1 (Peor score)	10%	79.53%	7.95x	Auditoría obligatoria, bloqueo de líneas de crédito no dispuestas y exigencia de garantías líquidas inmediatas.
Decil 2	20%	93.89%	4.69x	Revisión trimestral reforzada por el comité de riesgos y solicitud de colateral adicional.
Decil 3	30%	98.44%	3.28x	Seguimiento estándar de cumplimiento de <i>covenants</i> financieros ordinarios.
Decil 4	40%	99.56%	2.49x	Seguimiento estándar de cumplimiento de <i>covenants</i> financieros ordinarios.
Deciles 5 a 10	100%	100.00%	1.00x	Tramitación ágil, concesión automatizada y renovación comercial preferente sin trabas burocráticas.



6.2. Pruebas de resistencia macroeconómica (stress testing) y simulación Monte Carlo

Conforme a los estándares internacionales de gestión del riesgo bancario (directrices CCAR y DFAST (Board of Governors of the Federal Reserve System, 2024) y marcos de resistencia de la Autoridad Bancaria Europea - EBA), los modelos de calificación interna deben demostrar solvencia ante shocks macroeconómicos adversos.

Para estresar al modelo primero se ha sometido a tres escenarios deterministas de contextos económicos que se han dado en el pasado


- Shock de tipos de interés de la Fed: Subida de tipos oficiales de +450 puntos básicos, aumento del 60% en los gastos financieros por intereses y contracción de 2 desviaciones típicas en la distancia al default de Merton.
- Estancflación severa: Aumento de inflación en +500 puntos básicos, incremento del desempleo en +350 puntos básicos y caída del PIB real del 3%
- Recesión extrema: Caída del 30% en ingresos brutos, contracción del 50% en capital circulante, depreciación bursátil del 40% y contracción del 5% del PIB real(similar a la crisis financiera de 2008).

De manera adicional se ha sometido al modelo a una simulación de Montecarlo para calcular el Credit VaR (Jorion, 2006) sometiendo al modelo a una prueba de estrés mas robusta que los tres escenarios anteriores.

Tabla 12 Resultados de las pruebas de estrés Monte Carlo y Credit VaR (N = 10,000 y cartera 10,000 millones de USD)

Escenario Evaluado / Simulación	Tasa Media de Quiebra (%)	Variación vs. Base	Pérdida Esperada Post-Estrés (millones USD)	Incremento de Pérdida (millones USD)	Variación Económica (%)
Escenario Base (Histórico Normal)	14.00%	—	648.84	—	—
1. Estancflación Severa	21.90%	+56.4%	920.25	+271.41	+41.8%
2. Shock de Tipos de la Fed	24.80%	+77.1%	1,020.00	+371.16	+57.2%
3. Recesión Severa	31.10%	+122.1%	1,204.60	+555.77	+85.7%
Distribución Monte Carlo (Media 10,000 it.)	18.09%	+29.2%	1,085.40	+436.56	+67.3%
Credit VaR al 95% (Percentil 95)	20.90%	—	1,254.00	—	Pérdida Inesperada: 605.16
Credit VaR al 99% (Percentil 99)	21.70%	—	1,302.00	—	Pérdida Inesperada: 653.16

El credit VaR al 99% es de 1,302 millones de dólares, lo que supone un incremento de las pérdidas en 653.16 millones de dólares. Se puede determinar que las pérdidas han quedado contenidas en un margen razonable y asumible



6.3. Monitorización de estabilidad temporal y gobernanza de data drift (PSI y KS)

Un requisito en la gobernanza de modelos bancarios (Federal Reserve SR 11-7) es la monitorización continua de la degradación del modelo a lo largo del tiempo. Las carteras corporativas sufren cambios estructurales derivados de ciclos económicos, reformas fiscales u otras causas.

Para controlar esta evolución el sistema incorpora un módulo de vigilancia de deriva (data drift y prediction drift) basado en dos contrastes estadísticos:

- Índice de estabilidad poblacional (Population Stability Index - PSI): Mide cuantitativamente cuánto se ha desplazado la distribución de las variables o de las puntuaciones predichas respecto al periodo base de referencia.
- Test de Kolmogorov-Smirnov (KS) (Massey, F. J., 1951): Evalúa la distancia máxima entre las distribuciones acumuladas para verificar si el cambio poblacional es estadísticamente significativo.

Tabla 13 Protocolo regulatorio de control de deriva y umbrales de actuación operativa

Rango de estabilidad (PSI)	Nivel de deriva poblacional	Diagnóstico	Acción operativa hipotética
$PSI < 0.10$	Población estable	Comportamiento óptimo y sin alteraciones.	Mantener modelo en producción sin modificaciones.
$0.10 \leq PSI \leq 0.25$	Deriva moderada	Cambio incipiente en perfiles de clientes o macro.	Reforzar monitorización mensual y revisar variables clave.
$PSI > 0.25$	Deriva severa / Crítica	Ruptura estructural de la distribución base.	Reentrenamiento o recalibración.

Tabla 14 Resultados sobre el set de datos población de referencia <2021 y muestra 2022-2024

Variable	PSI	Estadístico KS	p-valor KS	Estado Regulatorio
macro_inflation	8.1858	1.0000	< 0.0001	Deriva Severa
macro_interest_rate	5.2032	0.8172	< 0.0001	Deriva Severa
macro_real_gdp_growth_yoy	1.8235	0.3048	< 0.0001	Deriva Severa
macro_regime_expansion_prob	1.0968	0.5103	< 0.0001	Deriva Severa
market_news_sentiment_mean	0.9154	0.1923	< 0.0001	Deriva Severa
news_sentiment_range_6m	0.5740	0.1512	< 0.0001	Deriva Severa
news_sentiment_avg	0.5517	0.2560	< 0.0001	Deriva Severa
tag_NetIncomeLoss	0.1193	0.0904	< 0.0001	Deriva Moderada
tag_RetainedEarningsAccumulatedDeficit	0.1105	0.1040	< 0.0001	Deriva Moderada
tag_CommonStockParOrStatedValuePerShare	0.0969	0.1302	< 0.0001	Estable
tag_Assets	0.0812	0.0945	< 0.0001	Estable
tag_CommonStockSharesAuthorized	0.0604	0.1223	< 0.0001	Estable
tag_CommonStockValue	0.0542	0.0936	< 0.0001	Estable
merton_distance_to_default	0.0492	0.0714	< 0.0001	Estable
market_cap	0.0401	0.0934	< 0.0001	Estable
tag_WorkingCapital	0.0399	0.0617	< 0.0001	Estable
corp_archetype_prob_2	0.0346	0.0356	< 0.0001	Estable
stock_price_close	0.0318	0.1045	< 0.0001	Estable
tag_EntityCommonStockSharesOutstanding	0.0197	0.0472	< 0.0001	Estable
corp_archetype_prob_1	0.0089	0.0218	< 0.0001	Estable
pub_lag_days	0.0038	0.0170	< 0.0001	Estable

Tabla 15 Resultados sobre la predicción

Modelo	Registros Históricos ($N_{\text{train}} \leq 2021$)	Registros Producción ($N_{\text{test_OOT}} > 2021$)	PD Media Train (≤ 2021)	PD Media Test OOT (> 2021)	PSI (Population Stability Index)	Estadístico KS (D_{KS})	Estado Regulatorio (Guía Fed SR 11-7)
XGBoost	284,337	108,994	0.2031	0.1703	0.0622	0.0674	Estable

Las variables macro y NLP presentan deriva severa respecto a la población del train, a priori podría resultar en un prediction drift y necesidad de reentrenamiento del modelo. En contraste los resultados sobre la predicción muestran un comportamiento estable lo que prueba que el modelo, al combinar distintas variables multimodales presenta robustez ante data drift, constatando al mismo tiempo que no ha sufrido de overfitting durante el entrenamiento y es capaz de generalizar.

7. EXPLICABILIDAD PARA NEGOCIO (XAI) Y CUMPLIMIENTO NORMATIVO

7.1. El imperativo regulatorio de la explicabilidad: superación de la caja negra

Los modelos de riesgos bancarios, especialmente si se enfocan al crédito necesitan ser explicables, así lo condiciona el siguiente marco regulatorio:

- Directrices de gestión del riesgo de modelos (Guía Federal Reserve SR 11-7 y directivas EBA): Exigen demostrar la solidez conceptual del sistema. Los comités de riesgos deben verificar que las predicciones obedecen a principios económicos y financieros lógicos, prohibiendo dependencias espurias o artefactos estadísticos.
- Reglamento europeo de inteligencia artificial (EU AI Act, Artículos 12 y 14): Clasifica a los sistemas de puntuación crediticia y evaluación de solvencia corporativa como sistemas de IA de alto riesgo. Esta normativa impone la obligación jurídica de garantizar la trazabilidad algorítmica, el registro de auditoría y la supervisión humana.
- Normativas de crédito justo y no discriminación (ECOA y FCRA): En la jurisdicción estadounidense, Consumer Financial Consumer Bureau (CFPB) (2022), la Equal Credit Opportunity Act (ECOA) (United states congress, 1974) y la Fair Credit Reporting Act (FCRA) (United states congress, 1970) obligan a cualquier entidad que deniegue o encarezca una línea de financiación a emitir una notificación motivada, comunicando formalmente las razones financieras específicas del rechazo

El sistema integra una capa de explicabilidad mediante valores SHAP (SHapley Additive exPlanations) (Lundberg y Lee, 2017), permitiendo auditar el comportamiento del modelo tanto a escala global de cartera como a nivel de cada expediente individual con el fin de cumplir con las anteriores regulaciones y que el modelo sea factible de llevar a producción.


7.2. Interpretabilidad global mediante valores SHAP (TreeExplainer)

Mediante el algoritmo TreeExplainer (Lundberg et al., 2020), adaptado a la topología de árboles de decisión, se descompone la predicción continua de cada empresa como la suma de un valor basal medio más el impacto de cada una de las 21 variables maestras: $\text{predicción}(x) = \phi_0 + \sum_{j=1}^{21} \phi_j(x)$

El análisis global de importancia SHAP sobre el censo de empresas revela qué dimensiones mueven con mayor fuerza la aguja del riesgo:

Tabla 16 Importancia relativa de las dimensiones predictivas en la decisión del modelo (SHAP)

Dimensión de información	Peso relativo en la decisión	Variables dominantes en el impacto	Explicación hipotética de negocio
Contabilidad y arquetipos corporativos	79.45%	Working capital, activos y beneficios entre otros	Evalúa la salud patrimonial intrínseca y la solvencia operativa.
Mercado bursátil y Merton KMV	17.77%	Distancia al default (DtD), capitalización bursátil y precio de cierre.	Incorpora la valoración de los inversores en tiempo real.
Entorno macroeconómico	1.67%	Inflación, tipo de interés y regímenes GMM	Modula la probabilidad de supervivencia según la fase del ciclo económico.
Textos y prensa financiera (NLP)	1.11%	Análisis de sentimiento nivel empresa y mercado	Señal temprana no estructurada de tensión previa a los balances.



7.3. Interpretabilidad local, interacciones no lineales y cartas de acción adversa (ECO A y FCRA)

7.3.1. Auditoría local de expedientes individuales (SHAP Waterfall)

A diferencia de los modelos tradicionales donde solo se conoce una puntuación agregada (WoE), la interpretabilidad local permite generar un gráfico de cascada (Waterfall Plot) para cada solicitud de crédito.

Los analistas de riesgos pueden descomponer de forma transparente por qué una empresa concreta (por ejemplo, con una probabilidad estimada de quiebra del 18.5%) supera el umbral operativo de corte ($\tau^*=0.158$), identificando con precisión qué magnitudes restaron solvencia y cuáles actuaron como mitigantes.

7.3.2. Generación automatizada de cartas de acción adversa

Para dar cumplimiento estricto a las exigencias de la CFPB, la Equal Credit Opportunity Act y el Artículo 13 del EU AI Act (European Parliament and Council, 2024), el sistema integra un generador algorítmico de notificaciones motivadas de denegación crediticia:

- Cuando el modelo asigna una probabilidad superior al umbral de riesgo, el algoritmo identifica las variables que registraron la mayor contribución adversa positiva ($\phi_j > 0$) para ese cliente específico.
- Traduce automáticamente los valores numéricos y los logits a términos financieros claros y comprensibles para el solicitante, garantizando una comunicación transparente y libre de sesgos discriminatorios.

Ejemplo real de dictamen motivado de acción adversa generado por el sistema:

NOTIFICACIÓN REGULATORIA DE ACCIÓN ADVERSA (ECO A / CFPB REGULATION B & EU AI ACT ART. 13)

Expediente Evaluado: Gryphon Digital Mining, Inc. (Ticker: ABTC | Ejercicio: 2024)
Probabilidad de Insolvencia (PD): 42.10% | Umbral Operativo de Concesión: 15.80%
Dictamen de Riesgo: SOLICITUD DE CRÉDITO DENEGADA / ALERTA DE REESTRUCTURACIÓN

FACTORES FINANCIEROS PRINCIPALES DETERMINANTES DE LA DENEGACIÓN (ORDENADOS POR IMPACTO SHAP):

- Fondo de maniobra neto (*tag_WorkingCapital*): Déficit crítico de -18.12 millones USD, actuando como el detonante principal de iliquidez corriente (impacto SHAP: +1.63).

- **Resultado neto contable** (*tag_NetIncomeLoss*): Pérdidas de -7.70 millones USD en el ejercicio, evidenciando un drenaje continuo de fondos y deterioro patrimonial (impacto SHAP: +0.22).
- **Inflación macroeconómica** (*macro_inflation*): Nivel de IPC en 313.57 puntos, comprimiendo los márgenes operativos ante costes crecientes de inputs y energía (impacto SHAP: +0.10).
- **Arquetipo de vulnerabilidad** (*corp_archetype_prob_2*): Probabilidad de pertenencia del 97.00% al clúster corporativo de empresas altamente apalancadas y con caja deficitaria (impacto SHAP: +0.05).
- **Tipo de interés oficial** (*macro_interest_rate*): Tipos de la Fed al 5.33%, encareciendo de forma severa la refinanciación de los pasivos exigibles a corto plazo (impacto SHAP: +0.04).

8. INTEGRACIÓN OPERATIVA EN NEGOCIO

8.1. Integración en el flujo de decisión crediticia y arquitectura operativa

Tras la fase de análisis, creación y validación del modelo es fundamental ponerlo en producción para ello se ha desplegado un sistema a través de FastAPI (Ramírez, 2018) y Docker para mejorar compatibilidad a la hora de la puesta en producción. Esto permite obtener el riesgo de quiebra en tiempo real integrándolo fácilmente en el sistema del banco.

8.1.1. Casos de uso de negocio en la operativa bancaria

Tabla 17 Casos de uso del motor analítico, usuarios destinatarios y tiempos de respuesta

Proceso de negocio	Usuario y canal	Decisión u output generado	Latencia observada	Impacto operativo en la entidad
Admisión ágil de crédito	Gestor comercial / Banca digital	Concesión automática o derivación a estudio	1.48-2.10 ms	Respuesta inmediata al cliente y reducción de costes operativos.
Comité de riesgos	Analista de riesgos	Probabilidad e informe de acción adversa	2.40-2.89 ms	Fundamentación técnica rigurosa y eliminación de discrecionalidad.
Monitorización de cartera	Control de riesgos	Reevaluación masiva de carteras completas	0.14 ms/empresa	Detección precoz de impagos y dotación preventiva de provisiones IFRS 9.
Auditoría regulatoria	Inspector interno / Supervisor	Certificación de trazabilidad y gobernanza	1.20-1.27 ms	Blindaje ante sanciones del regulador (EBA, Fed, EU AI Act).

8.1.2. Blindaje contra errores de entrada y calidad del dato en origen

El sistema incorpora una capa de validación funcional estricta que verifica en el momento de la solicitud la coherencia contable y de mercado del expediente (evitando patrimonios netos incoherentes o campos nulos no declarados), garantizando que ningún cálculo de riesgo se ejecute sobre datos no fiables

8.1.3. Registro de operaciones y seguridad jurídica (EU AI Act, Artículo 12)

Para cumplir con los requerimientos jurídicos del EU AI Act sobre sistemas de alto riesgo y a las normativas de crédito justo (ECO/CFPB), cada dictamen emitido por el sistema queda grabado:

- Se registra la fecha y microsegundo exacto de la decisión, la versión y huella digital del modelo utilizado, la totalidad de variables financieras de la empresa y la probabilidad estimada.
- Se almacena la justificación técnica de la decisión: si una operación es rechazada, quedan fijadas automáticamente las magnitudes financieras causales del rechazo, permitiendo notificar al cliente sus motivos legales de forma transparente.

9. CONCLUSIONES Y VÍAS DE MEJORA

9.1. Conclusiones

El proyecto demuestra que emplear algoritmos avanzados en la detección de riesgos mejora el enfoque tradicional en rendimiento y rentabilidad sin renunciar a explicabilidad exigida por los reguladores.

- La fijación de un umbral de decisión sustentado en la asimetría real del coste de insolvencia ($\tau^*=0.158$), sumada a la precisión del modelo XGBoost genera un ahorro neto de 3,684 millones de dólares de media en cada fold frente a modelos clásicos como la regresión logística.

- En el machine learning tradicional se tiende a calibrar los modelos optimizando métricas de precisión como ROC-AUC o PR-AUC, en este trabajo se ha demostrado que los modelos se pueden calibrar optimizando la función de coste de negocio lo que en la práctica resulta más útil.
- Demostración de que los modelos tradicionales basados en magnitudes contables son necesarios pero insuficientes. La combinación de métricas de mercado, sentimiento de noticias financieras y magnitudes macroeconómicas permite anticipar el colapso financiero con hasta 24 meses de margen de maniobra.
- Calibración probabilística y cumplimiento con IFRS 9 / Basilea: Mediante Platt Scaling se redujo el Brier Score en un 28.8% (de 0.0462 a 0.0329). La evaluación decil a decil basada en el contraste de Hosmer-Lemeshow y la curva de fiabilidad certifica que las probabilidades estimadas se alinean estrechamente con las frecuencias reales observadas de quiebra (reduciendo la distorsión en un 88.5%), condición indispensable para el cálculo fiable de provisiones contables y requerimientos de capital.
- Bajo escenarios de severa contracción económica simulados mediante 10,000 iteraciones Monte Carlo el modelo mantiene capacidad de captura de quiebras asegurando que el sistema no pierde excesiva fiabilidad durante cambios de condiciones económicas y contiene las pérdidas en un margen razonable.
- Conectando con el punto anterior se concluye que el modelo presenta robustez ante la deriva de datos y capacidad de generalización en distintos contextos macroeconómicos.
- Superación del dilema entre precisión y explicabilidad. La incorporación nativa de valores SHAP, las cartas automáticas de acción adversa para la CFPB y el registro de auditoría alineado con el EU AI Act demuestran que los modelos no lineales pueden cumplir los estándares regulatorios del sector financiero.

9.2. Vías de mejora

El proyecto se ha construido sobre datos gratuitos y de libre acceso, durante el desarrollo han surgido ideas que han sido difíciles de implementar debido a la falta de datos. En términos generales la principal vía de mejora sería superar esta restricción. En un contexto de un banco donde se tiene acceso a bases de datos con mayor alcance el modelo se podría enriquecer con las siguientes ideas:

- Uso de datos bancarios de alta frecuencia, mientras que la información pública de la SEC muestra el balance trimestral con meses de retraso, un banco monitoriza a diario las entradas y salidas de tesorería, la evolución del saldo en cuenta corriente, registro de morosidad o incluso puede llegar a acuerdos con las empresas para que les presenten balances con mayor frecuencia. Estas señales únicamente disponibles en la base de datos del banco permitirían detectar tensiones de caja meses antes de que se reflejen en los balances oficiales.
- En este trabajo se planteó el uso de modelos que permitan analizar el comportamiento conjunto de entidades con el fin de tener en cuenta el riesgo de contagio sectorial, como por ejemplo árboles Mantegna (1999). La forma en la que se planteó fue a través de los precios de las acciones, sin embargo, tan solo el 20% de las empresas eran cotizadas lo que obstaculizó la implementación. A través de bases de datos de transacciones se podría llevar a la práctica esta idea que podría aportar señales predictivas potentes.
- En un banco el área de análisis económico y riesgos emite informes cualitativos sobre el contexto macro y empresas en cartera, el análisis de sentimiento NLP se podría enriquecer alimentándose de estos informes.
- Para mejorar la estimación de las pérdidas, la cual se ha hecho con un caso hipotético estándar, la base de datos de un banco permitiría incorporar el valor de garantías asociadas a una operación, completando el cálculo de la pérdida en caso de impago (Loss Given Default o LGD) y de la pérdida esperada neta requerida por Basilea e IFRS 9.

Bibliografía

Akiba, T., Sano, S., Yanase, T., Ohta, T. and Koyama, M. (2019). 'Optuna: A next-generation hyperparameter optimization framework', in *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining*. Anchorage, AK: ACM, pp. 2623–2631.

Altman, E. I. (1968). 'Financial ratios, discriminant analysis and the prediction of corporate bankruptcy', *The Journal of Finance*, 23(4), pp. 589–609.

Araci, D. (2019). 'FinBERT: Financial sentiment analysis with pre-trained language models', *arXiv preprint*, arXiv:1908.10063.

- Basel Committee on Banking Supervision [BCBS] (2017). *Basel III: Finalising post-crisis reforms*. Basel: Bank for International Settlements (BIS).
- Black, F. and Scholes, M. (1973). 'The pricing of options and corporate liabilities', *Journal of Political Economy*, 81(3), pp. 637–654.
- Board of Governors of the Federal Reserve System (2011). *Supervisory Guidance on Model Risk Management (SR Letter 11-7)*. Washington, D.C.: Federal Reserve Board.
- Board of Governors of the Federal Reserve System (2024). *Dodd-Frank Act Stress Testing (DFAST) and Comprehensive Capital Analysis and Review (CCAR): Supervisory Scenarios for Annual Stress Tests*. Washington, D.C.: Federal Reserve Board.
- Breiman, L. (2001). 'Random forests', *Machine Learning*, 45(1), pp. 5–32.
- Brier, G. W. (1950). 'Verification of forecasts expressed in terms of probability', *Monthly Weather Review*, 78(1), pp. 1–3.
- Chen, T. and Guestrin, C. (2016). 'XGBoost: A scalable tree boosting system', in *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. San Francisco, CA: ACM, pp. 785–794.
- Consumer Financial Protection Bureau [CFPB] (2022). *Consumer Financial Protection Circular 2022-03: Adverse action notification requirements in connection with credit decisions based on complex algorithms*. Washington, D.C.: CFPB.
- DeLong, E. R., DeLong, D. M. and Clarke-Pearson, D. L. (1988). 'Comparing the areas under two or more correlated receiver operating characteristic curves: A nonparametric approach', *Biometrics*, 44(3), pp. 837–845.
- Dempster, A. P., Laird, N. M. and Rubin, D. B. (1977). 'Maximum likelihood from incomplete data via the EM algorithm', *Journal of the Royal Statistical Society: Series B (Methodological)*, 39(1), pp. 1–38.
- Devlin, J., Chang, M.-W., Lee, K. and Toutanova, K. (2019). 'BERT: Pre-training of deep bidirectional transformers for language understanding', in *Proceedings of the 2019 Conference of the North American Chapter of the Association for Computational Linguistics: Human Language Technologies (NAACL-HLT)*. Minneapolis, MN: Association for Computational Linguistics, pp. 4171–4186.
- Edwards, A. L. (1948). 'Note on the "correction for continuity" in testing the significance of the difference between correlated proportions', *Psychometrika*, 13(3), pp. 185–187.
- Efron, B. and Tibshirani, R. J. (1994). *An Introduction to the Bootstrap*. New York: Chapman & Hall/CRC.
- European Banking Authority [EBA] (2017). *Guidelines on the application of the definition of default under Article 178 of Regulation (EU) No 575/2013 (EBA/GL/2016/07)*. Paris: European Banking Authority.
- European Parliament and Council (2024). *Regulation (EU) 2024/1689 of the European Parliament and of the Council of 13 June 2024 laying down harmonised rules on artificial intelligence (Artificial Intelligence Act)*. Official Journal of the European Union, L 2024/1689.
- Federal Reserve Bank of St. Louis (2024). *Federal Reserve Economic Data (FRED)*. St. Louis, MO: Federal Reserve Bank of St. Louis. Disponible en: <https://fred.stlouisfed.org>.
- Grootendorst, M. (2022). 'BERTopic: Neural topic modeling with a class-based TF-IDF procedure', *arXiv preprint*, arXiv:2203.05794.
- Hosmer, D. W. and Lemeshow, S. (2000). *Applied Logistic Regression*. 2nd edn. New York: John Wiley & Sons.
- International Accounting Standards Board [IASB] (2014). *International Financial Reporting Standard 9: Financial Instruments (IFRS 9)*. London: IFRS Foundation.
- Jorion, P. (2006). *Value at Risk: The New Benchmark for Managing Financial Risk*. 3rd edn. New York: McGraw-Hill.
- Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., Ye, Q. and Liu, T.-Y. (2017). 'LightGBM: A highly efficient gradient boosting decision tree', in *Advances in Neural Information Processing Systems (NeurIPS 30)*. Long Beach, CA: Curran Associates, pp. 3146–3154.
- López de Prado, M. (2018). *Advances in Financial Machine Learning*. Hoboken, NJ: John Wiley & Sons.
- Lundberg, S. M. and Lee, S.-I. (2017). 'A unified approach to interpreting model predictions', in *Advances in Neural Information Processing Systems (NeurIPS 30)*. Long Beach, CA: Curran Associates, pp. 4765–4774.
- Lundberg, S. M., Erion, G., Chen, H., DeGrave, A., Prutkin, J. M., Nair, B., Katz, R., Himmelfarb, J., Bansal, N. and Lee, S.-I. (2020). 'From local explanations to global understanding with explainable AI for trees', *Nature Machine Intelligence*, 2(1), pp. 56–67.
- Mantegna, R. N. (1999). 'Hierarchical structure in financial markets', *The European Physical Journal B - Condensed Matter and Complex Systems*, 11(1), pp. 193–197.
- Massey, F. J. (1951). 'The Kolmogorov-Smirnov test for goodness of fit', *Journal of the American Statistical Association*, 46(253), pp. 68–78.
- McNemar, Q. (1947). 'Note on the sampling error of the difference between correlated proportions or percentages', *Psychometrika*, 12(2), pp. 153–157.
- Merton, R. C. (1974). 'On the pricing of corporate debt: The risk structure of interest rates', *The Journal of Finance*, 29(2), pp. 449–470.

- Navas-Palencia, G. (2020). 'Optimal binning: mathematical programming formulation', *arXiv preprint*, arXiv:2001.08025.
- Platt, J. C. (1999). 'Probabilistic outputs for support vector machines and comparisons to regularized likelihood methods', in Smola, A. et al. (eds.) *Advances in Large Margin Classifiers*. Cambridge, MA: MIT Press, pp. 61–74.
- Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V. and Gulin, A. (2018). 'CatBoost: unbiased boosting with categorical features', in *Advances in Neural Information Processing Systems (NeurIPS 31)*. Montreal, Canada: Curran Associates, pp. 6638–6648.
- Raasveldt, M. and Mühleisen, H. (2019). 'DuckDB: an embeddable analytical database', in *Proceedings of the 2019 International Conference on Management of Data (SIGMOD '19)*. Amsterdam: ACM, pp. 1981–1984.
- Ramírez, S. (2018). *FastAPI: Modern, high-performance web framework for building APIs with Python*. Disponible en: <https://fastapi.tiangolo.com>.
- Siddiqi, N. (2017). *Credit Risk Scorecards: Developing and Implementing Intelligent Credit Scoring*. Hoboken, NJ: John Wiley & Sons.
- Spearman, C. (1904). 'The proof and measurement of association between two things', *The American Journal of Psychology*, 15(1), pp. 72–101.
- Sun, X. and Xu, W. (2014). 'Fast implementation of DeLong's algorithm for comparing the areas under correlated receiver operating characteristic curves', *IEEE Signal Processing Letters*, 21(11), pp. 1389–1393.
- U.S. Securities and Exchange Commission [SEC] (2024). *Electronic Data Gathering, Analysis, and Retrieval (EDGAR) System*. Washington, D.C.: U.S. Securities and Exchange Commission. Disponible en: <https://www.sec.gov/edgar>.
- United States Congress (1970). *Fair Credit Reporting Act (FCRA)*, 15 U.S.C. § 1681 et seq. Washington, D.C.: U.S. Government Publishing Office.
- United States Congress (1974). *Equal Credit Opportunity Act (ECOA)*, 15 U.S.C. § 1691 et seq. Washington, D.C.: U.S. Government Publishing Office.